Informatik 1: Problemlösung

Wirtschaftsingenieurwesen Bachelor

Dorian Zwanzig / 18.10.2024

htw.
Hochschule für Technik
und Wirtschaft Berlin
University of Applied Sciences

Agenda

1	Einsatz generativer KI Tools
2	EVA Prinzip
3	Daten-Informationen-Wissen
4	CRISP DM
5	Problemlösungsprozess

0. TL:DL [to long, didn‘t listen]

- **Einsatz generativer KI Tools:** Nutzen Sie KI-Tools wie ChatGPT, um Ihre praktischen Fähigkeiten zu verbessern und ein tieferes Verständnis für die Materie zu erlangen.
- **Daten-Informationen-Wissen:** Wissen ist Informationen mit Interpretation, Informationen sind Daten mit Kontext, Daten sind nur „Werte“
- **CRISP DM/ Pröblemlösungsprozess nach Haberfellner:** Es existieren unterschiedliche strukturierte Herangehensweisen für die Lösung von Aufgaben/Problemen. Diese können dabei helfen eine optimale Lösung zu finden.
- **EVA Prinzip:** Eingabe, Verarbeitung und Ausgabe ist ein Prozess, den Sie in jedem Informationssystem wiederfinden werden.

0. Glossar

- **Data Mining:** Data Mining ist der Prozess des Auffindens von Mustern, Korrelationen und Anomalien in großen Datenmengen (Datenbeständen) mit dem Ziel, sinnvolle Informationen zu extrahieren, die für Geschäftsentscheidungen, Prognosen und andere Anwendungen nützlich sein können. Es nutzt Methoden aus Statistik, maschinellem Lernen und künstlicher Intelligenz, um historische Daten zu durchsuchen und Vorhersagemodelle zu erstellen.
- **Data Science:** Data Science ist ein interdisziplinäres Feld, das wissenschaftliche Methoden, Prozesse, Algorithmen und Systeme verwendet, um Wissen und Erkenntnisse aus strukturierten und unstrukturierten Daten zu gewinnen und zu analysieren.
- **Feature:** In Data Science bezeichnet ein Feature ein individuelles messbares Eigenschafts- oder Charakteristikum, das für die Analyse verwendet wird. Im Kontext von maschinellem Lernen sind Features die Eingabevariablen, die in ein Modell eingespeist werden.

0. Glossar

- **Methode:** Eine Methode ist ein definierter, systematischer Prozess oder eine Vorgehensweise, um eine Aufgabe zu erfüllen oder ein Problem zu lösen. In der Programmierung ist eine Methode eine Funktion, die einem Objekt oder einer Klasse zugeordnet ist.
- **Modell:** Ein Modell (in Data Science) ist eine vereinfachte Darstellung der Realität, die geschaffen wird, um bestimmte Aspekte der Daten zu verstehen und Vorhersagen oder Entscheidungen zu treffen. In der Informatik kann ein Modell eine Abstraktion sein, die zur Beschreibung und Analyse eines Systems dient.
- **Vorgehensmodell:** Ein Vorgehensmodell ist ein Rahmen oder eine strukturierte Sammlung von Praktiken und Kriterien, die den Prozess der Softwareentwicklung oder des Projektmanagements leiten. Es gibt die Schritte vor, die zur erfolgreichen Durchführung eines Projekts erforderlich sind.

1. Einsatz generativer KI-Tools.

„Und was ist mit ChatGPT und so?“

1. Einsatz generativer KI-Tools.

… Chancen in der Arbeitswelt [und Studium?]

- Umfangreiche Studie durch Dell‘Acqua et.al. im Beratungskontext durchgeführt, um das Leistungssteigerungspotenzial durch den Einsatz von Generativer Künstlicher Intelligenz (GenKI) zu untersuchen
- 750 Berater einbezogen
- Deutliche Produktivitätssteigerung (bis zu 25% schneller)
- Deutliche Qualitätssteigerung (bis zu 40% besser)
- Insbesondere Berater mit „durchschnittlichen“ Leistungen profitieren stark (43% vs 17%)

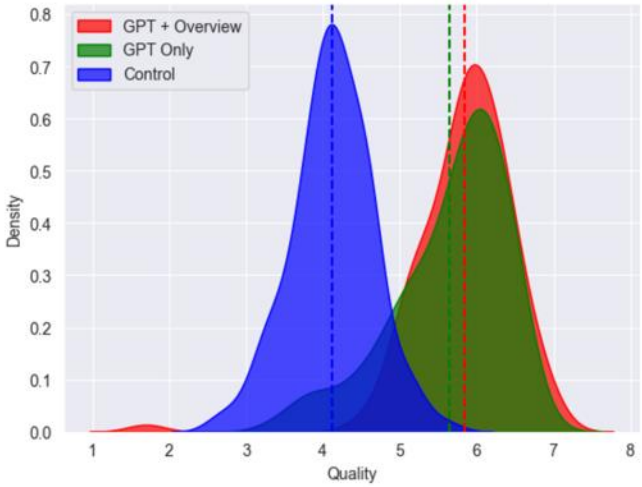

Dell'Acqua et.al., Navigating the Jagged Technological Frontier: Field Experimental Evidence of the Effects of AI on Knowledge Worker Productivity and Quality (September 15, 2023). Harvard Business School Technology & Operations Mgt. Unit Working Paper No. 24-013, Available at
SSRN: https://ssrn.com/abstract=4573321 or http://dx.doi.org/10.2139/ssrn.4573321

1. Einsatz generativer KI-Tools.

… als Werkzeug im Requirements Engineering

- **Forschungsziel:** Untersuchung des Einsatzes von Large Language Models (LLMs), insbesondere GPT-3.5 und GPT-4, zur Identifikation und Extraktion von Nutzeranforderungen aus natürlichsprachlichen Quellen
- **Methodik:** Fallstudie in der Physiotherapie, semi-strukturierte Interviews, Verarbeitung durch OpenAI-Modelle
- **Ergebnisse:** GPT-3.5 und GPT-4 zeigten ähnliche Leistungen in der Anforderungserkennung. Beide Modelle konnten relevante Anforderungen aus Texten extrahieren und sogar neue, vorher unbekannte Anforderungen identifizieren.
- Kennzahlen (nach Bereinigung) GPT-3.5: Sensitivität 71%, GPT-4: Sensitivität 73%
- Siehe SIENA: Sprachmodellbasierte Identifikation und Extraktion von Nutzeranforderungen, Zwanzig, Dorian; Dietrich, Ute. In: INFORMATIK 2023 - Designing Futures: Zukünfte gestalten. Bonn: 2023, S. 253-263. Konferenzbeitrag › Konferenzpaper › 2023

Aufgabe

Diskutiert in der Gruppe, mit dem Nachbarn/der Nachbarin und/oder eurem ChatGPT/Gemini/Claude/... über folgende Frage:

Sollte man ChatGPT zum lernen im Grundlagenmodul Informatik einsetzen?

- Was spricht dafür?
- Was spricht dagegen?
- Gibt es ein sinnvolles „Wie?“

Welchen Effekt hat die Nutzung von ChatGPT und anderen LLM Anwendungen auf den Lernerfolg von Studierenden der Informatik?

Die Nutzung von ChatGPT und anderen LLMs hat unterschiedliche Effekte auf den Lernerfolg von Informatikstudierenden: erklärende und ergänzende Nutzung führt zu positiven Lerneffekten, während überwiegend lösungsorientierte Nutzung für Codegenerierung und Debugging mit negativen Effekten verbunden ist.

Abstract

Zehn Studien aus verschiedenen Informatiklehrveranstaltungen dokumentieren, dass ChatGPT und vergleichbare Large Language Models (LLM) unterschiedliche Effekte auf den Lernerfolg haben. Die Studien messen Lernergebnisse mittels Endnoten, Examens- und Testpunkten, Programmierfähigkeiten, Engagement sowie studentischen Wahrnehmungen. Dabei berichteten die Studien:

1. Bei der Nutzung von LLMs zu erklärenden und ergänzenden Zwecken fanden sich positive Lerneffekte. So erzielte beispielsweise Lyu et al. (2024) eine Verbesserung von 12,5 Punkten in der Endnote ($p < 0{,}05$) und Nie et al. (2024) berichteten bei Anwendern einen Examensanstieg um 6,8 Prozentpunkte.
2. Eine überwiegend lösungsorientierte Nutzung, z. B. für Codegenerierung und Debugging, wurde teilweise mit negativen Effekten in Verbindung gebracht. Jošt et al. (2024) fanden hier signifikante negative Zusammenhänge (Spearman's $\rho = -0{,}305$ bis $-0{,}360$, $p < 0{,}05$).
3. Die berichteten Effekte hängen von Faktoren wie der Qualität der Eingabeprompts, der Häufigkeit der Nutzung, den Aufgabenmerkmalen und dem didaktischen Kontext ab.

Die Studien belegen demnach, dass der gezielte Einsatz von LLM-Anwendungen, etwa als ergänzende Erklärhilfe, Lernleistungen von Informatikstudierenden verbessern kann, während übermäßige Nutzung zur direkten Problemlösung mit Nachteilen einhergehen kann.

1. Einsatz generativer KI-Tools.

... als Werkzeug in diesem Kurs

- Verwenden Sie KI-Tools wie ChatGPT und andere für ihr Studium
- Kritische Auseinandersetzung mit den Fähigkeiten und den Ergebnissen zwingend notwendig
- Geben Sie an welche Tools sie eingesetzt haben
- ... und wo und wie Sie diese Tools eingesetzt haben
- Eine Nicht-Nennung des Einsatzes ist ein **Plagiat**
- **Die Lösung Ihrer Übungsaufgaben muss eigentständig erfolgen! GenKI Einsatz zur Erstellung der Lösung ist unzulässig und wird als Plagiat gewertet.**
- GenKI Tools sind insbesondere gut geeignet, um sich vorhandene Lösungen erklären zu lassen bspw: „Erkläre mir die Funktion A“ oder „Warum bekomme ich einen Fehler bei Funktion B?“

1. Einsatz generativer KI-Tools.

… als Teil von Google Colab

- In die Programmierumgebung Google Colab ist bereits generative KI integriert
- Funktionen:
  - Code generieren – Prompt notwendig, der die Aufgabe beschreibt
  - Code korrigieren – Code wird automatisch von Fehlern bereinigt
- Empfehlung:
  - Nutzt die „Code generieren“ Funktion nur in Ausnahmefällen – bspw. Alternative Lösungen suchen
  - verwendet die „Code generieren“ Funktion mit großer Aufmerksamkeit

Generate | Erstelle eine Funktion, die zwei Werte entgegennimmt und sie | Close

1 of 1 | Use code with caution

[1]

```
# prompt: Erstelle eine Funktion, die zwei Werte entgegennimmt und sie mi

def multipliziere(wert1, wert2):
  """Multipliziert zwei Werte und gibt das Ergebnis zurück."""
  return wert1 * wert2

# Beispielaufruf:
ergebnis = multipliziere(5, 3)
print(ergebnis)  # Ausgabe: 15
```

[4]

```
-def multipliziere(wert1, wert1):
+def multipliziere(wert1, wert2):
  """Multipliziert zwei Werte und gibt das Ergebnis zurück."""
  return wert1 * wert2

+# Beispielaufruf:
+ergebnis = multipliziere(5, 3)
+print(ergebnis)  # Ausgabe: 15
+
+
# Beispielaufruf:
ergebnis = multipliziere(5, 3)
print(ergebnis)  # Ausgabe: 15
```

2. EVA-Prinzip.
Eingabe, Verarbeitung, Ausgabe

2. EVA-Prinzip.

Betrachtungsgegenstand: Computersystem

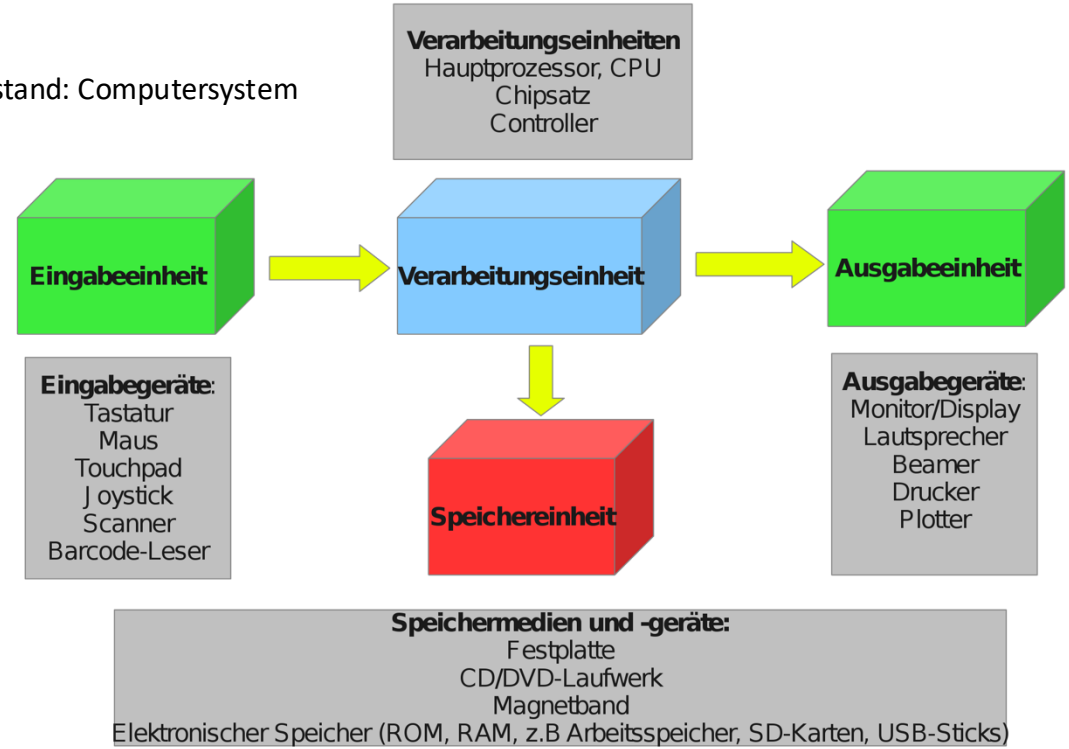

Bildquelle: https://de.wikipedia.org/wiki/EVA-Prinzip#/media/Datei:EVA-Prinzip.svg

2. EVA-Prinzip.

Betrachtungsgegenstand: Programm/Prozess

Eingabe → Verarbeitung (Prozess) → Ausgabe

```
paint_shop has 0 parts in machine i.e. {'body_b': 0,
'drive_system_a': 0} at day 38, hour 1.45
paint_shop got part 1 part body_b from body_b-storage,
current stock 1 at day 38, hour 1.49
paint_shop got part 1 part drive_system_a from
drive_system_a-storage, current stock 2 at day 38, hour
1.52
paint_shop has 2 parts in machine i.e. {'body_b': 1,
'drive_system_a': 1} at day 38, hour 1.52
```

Verfügbarkeitsfaktor	0,646
Leistungsfaktor	0,849
Qualitätsfaktor	0,959
OEE	52,6%

Prof. Dr.-Ing. Dietrich, Ute, Vorlesungsskript Systems Engineering, modifiziert

3. Daten-Informationen-Wissen.
Was ist was?! Und warum eigentlich?

3. Daten, Information, Wissen.

Daten - Syntaktik

- Zeichen, z.B. a-z, A-Z, 0-9
- Zeichenvorrat + Syntax (Regeln für erlaubte Zeichenkombinationen) = Daten
- IT- existieren auf bestimmten Datenträgern
- z.B. Datenelement vom Typ Integer: 181

Information - Semantik

- Bedeutung verschiedener Datenelemente, d.h. Interpretation der Datenelemente z.B. durch kognitive Tätigkeiten des Empfängers
- 181 ist die Größe von Herrn Mustermann in cm

Wissen - Pragmatik

- kontextspezifische Anwendung von Information (und Daten) für einen Zweck
- Berechnen der Durchschnittsgröße zur Konstruktion einer Parkbank

Prof. Dr.-Ing. Dietrich, Ute, Vorlesungsskript Informatik II

3. Daten, Information, Wissen.

Daten vs. Information – der Blick in die ISO Norm

Daten: Laut ISO IEC 2382-1 (1993) [7] sind Daten in der Informationstechnik eine wieder interpretierbare Darstellung von Informationen in formalistischer Art, geeignet zur Kommunikation, Interpretation und Verarbeitung.
Ihr Inhalt wird meist in Zeichen kodiert, deren Aufbau strengen Regeln (der sog. Syntax) folgt.

Information (das „In-Form“ gebrachte): werden aus Daten gewonnen, indem sie in einem Bedeutungszusammenhang interpretiert werden (der sog. Semantik).

Signal: ist die Darstellung einer Information. Es ist eine physikalische Größe, bei der ein oder mehrere Parameter (sog. Informationsparameter) Information über eine oder mehrere variable Größen tragen.

Prof. Dr.-Ing. Dietrich, Ute, Vorlesungsskript Informatik II: nach „Grundlagen Automatisierungstechnik“, S. 37, B. Heinrich et al, Springer Verlag, 3. Auflage 2020, modifiziert

3. Daten, Information, Wissen.

Wissen = Information + Interpretation/ Klassifikation

Information = Daten + Zweckbezug

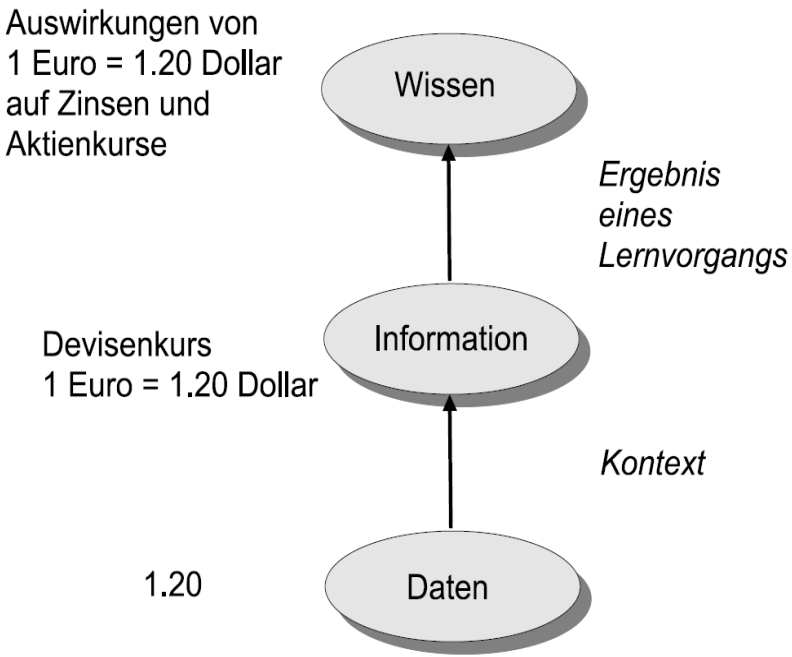

Prof. Dr.-Ing. Dietrich, Ute, Vorlesungsskript Informatik II

3. Daten, Information, Wissen.

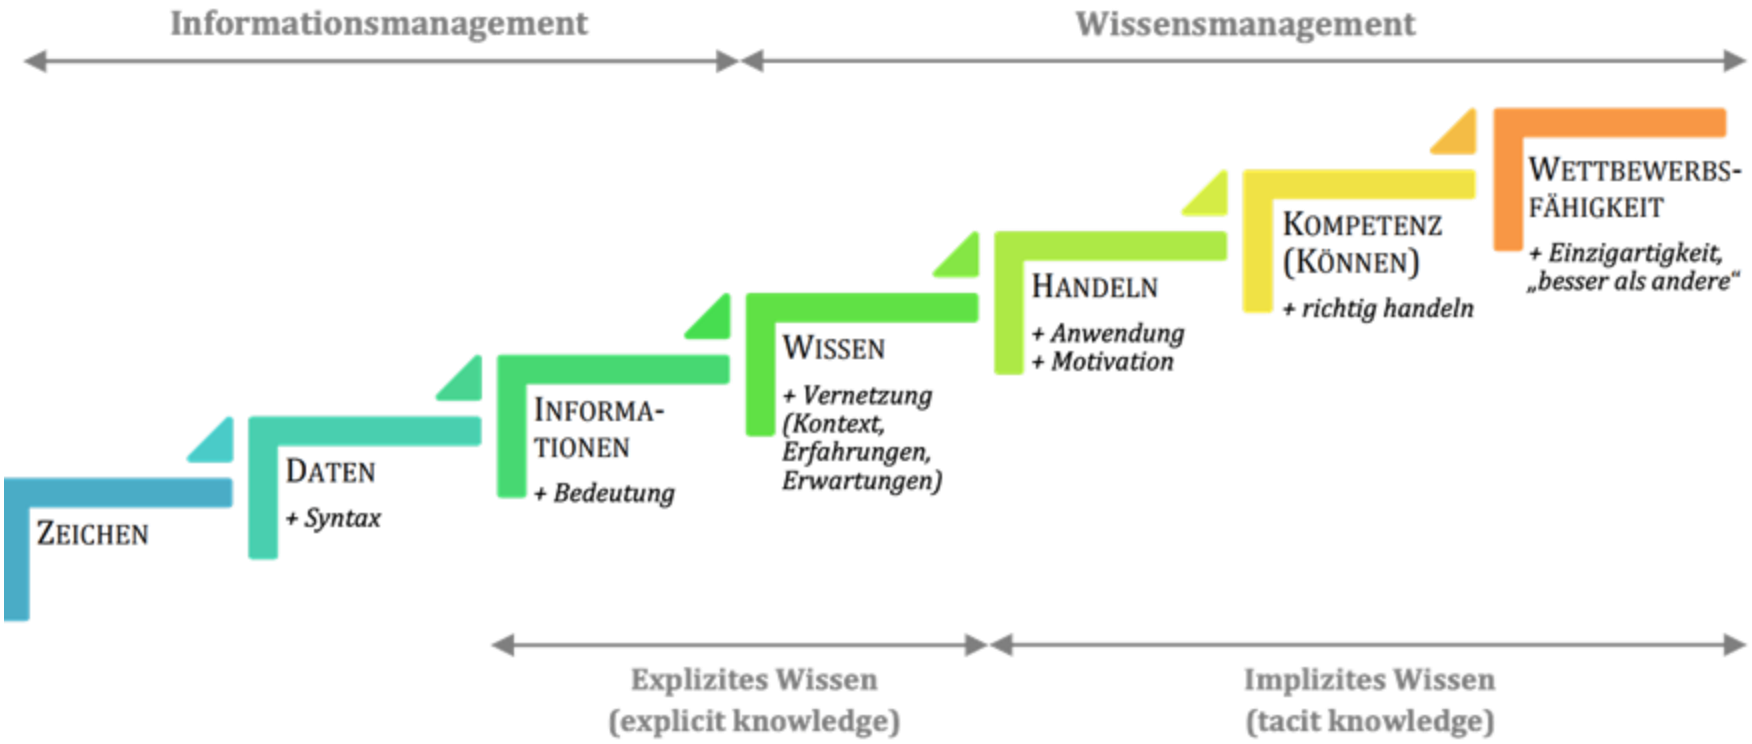

Die Wissenstreppe nach NORTH (Quelle: NORTH 2011: 36, Abb. 2-1; verändert und erweitert durch Jana Zscheischler)

4. Problemlösungsprozess nach Haberfellner. Mikrologik der Problemlösung.

4. Problemlösungsprozess nach Haberfellner.

Allgemeine Beschreibung

- Basiert auf der Dewey'schen Problemlösungslogik (Hall 1962)
- Mikrologik, die in jeder (Projekt)Phase angewendet werden kann

Schwerpunkte

- Zielsuche: Wo stehen wir? Was brauchen wir?
- Lösungssuche: Welche Möglichkeiten gibt es?
- Auswahl: Welche Lösung ist zweckmäßig?

i.A.a. Haberfellner 2012, Systems Engineering, 12. Auflage, orell füssli

4. Problemlösungsprozess nach Haberfellner.

Anstoß

- Auslöser für den Beginn des Problemlösungsprozess, bspw. Aufgabenstellung, Projektauftrag, Problemidentifikation, vorangegangener Problemlösungsprozess

i.A.a. Haberfellner 2012, Systems Engineering, 12. Auflage, orell füssli

4. Problemlösungsprozess nach Haberfellner.

Zielsuche

Situationsanalyse

- Das Problem wird ergründet und verstanden
- Ggf. werden Nachfragen gestellt
- Ein fundiertes Problemverständnis ist für eine zufriedenstellende Lösung zwingend notwendig
- Ergebnis sind qualitative und quantitative Informationen über das Problem
- Klare Unterscheidung zwischen Fakten und Interpretation
- „Was wird konkret von mir verlangt?“ „Was weiß ich bereits? „Was muss ich noch wissen?“

i.A.a. Haberfellner 2012, Systems Engineering, 12. Auflage, orell füssli

4. Problemlösungsprozess nach Haberfellner.

Zielsuche

<u>Zielformulierung</u>

- Ergebnisse der Situationsanalyse sind Informationsquelle für die Formulierung der Ziele
- Ziele sollen lösungsneutral, vollständig, verständlich und realistisch sein
- Ziele sollten immer priorisiert werden, bspw.
  Muss: Zwingend notwending
  Kann: wünschenswert, aber nicht notwendig
- Detailgrad der Zielformulierung von der Komplexität der Aufgabe abhängig

i.A.a. Haberfellner 2012, Systems Engineering, 12. Auflage, orell füssli

4. Problemlösungsprozess nach Haberfellner.

Lösungssuche

<u>Synthese von Lösungen</u>

- Finden von zum Problem passenden Lösungsmöglichkeiten
- Konstruktiver, kreativer Schritt welcher konkrete, bewertbare Lösungsansätze hervorbringt
- Anwendung von Kreativitätstechniken (bspw. Brainstorming, Brainwriting, Mindmapping etc.) i.d.R. in Arbeitsgruppen nützlich
- Es findet i.d.R. bereits eine intuitive Analyse statt
- Beschreibung der Lösungsansätze in passendem Detailierungsgrad

i.A.a. Haberfellner 2012, Systems Engineering, 12. Auflage, orell füssli

4. Problemlösungsprozess nach Haberfellner.

Lösungssuche

Analyse von Lösungen

- Strukturierte Untersuchung der gefunden Lösungen
- Analytisch, destruktiver Prozess Schritt, in dem herausgearbeitet wird, ob eine Idee als Lösung geeignet ist
- Untersucht werden u.a.:
  - Formale Aspekte (werden die Muss-Ziele erfüllt, gibt es Konflikte bei der Zielerfüllung)
  - Ressourcen für die Umsetzung vorhanden (HW,SW,Skills,Zeit, etc.)
  - Mögliche Auswirkungen auf andere Problemlösungen

i.A.a. Haberfellner 2012, Systems Engineering, 12. Auflage, orell füssli

4. Problemlösungsprozess nach Haberfellner.

Auswahl

<u>Bewertung</u>

- Verbliebenden Lösungsansätze werden systematisch gegenübergestellt
- Häufig wird bereits eine Lösung präferiert – Achtung: Kann zur suboptimalen Auswahl führen
- Lösungsansätze werden hinsichtlich des Grad der Zielerfüllung und der Umsetzbarkeit verglichen, bspw: Nutzertanalyse, Kosten-Nutzen-Rechnung…
- Bewertung in Gruppen kann Subjektivität reduzieren und Qualität der Auswahl verbessern

i.A.a. Haberfellner 2012, Systems Engineering, 12. Auflage, orell füssli

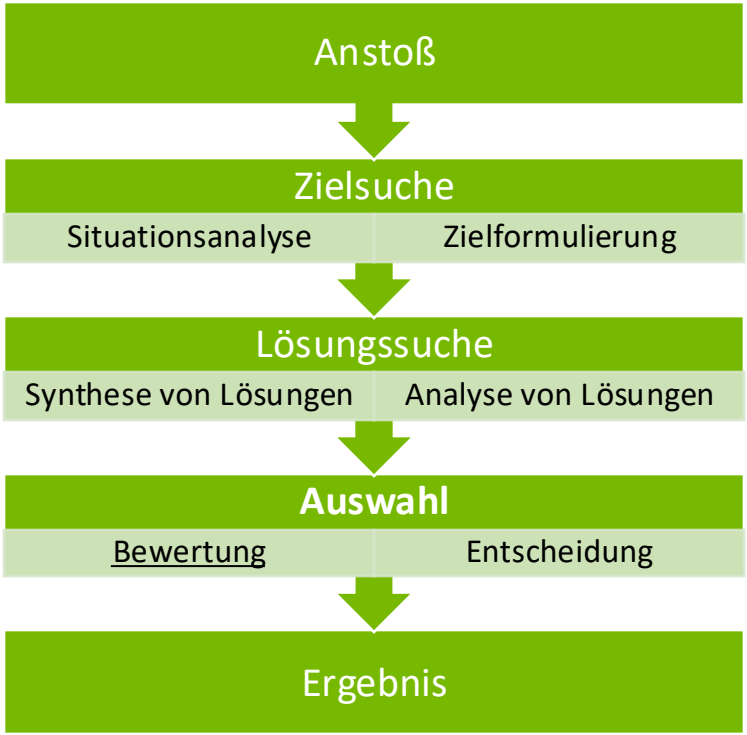

4. Problemlösungsprozess nach Haberfellner.

Auswahl

<u>Entscheidung</u>

- Weiter zu bearbeitende Lösung wird festgelegt
- Basis ist die Bewertung

i.A.a. Haberfellner 2012, Systems Engineering, 12. Auflage, orell füssli

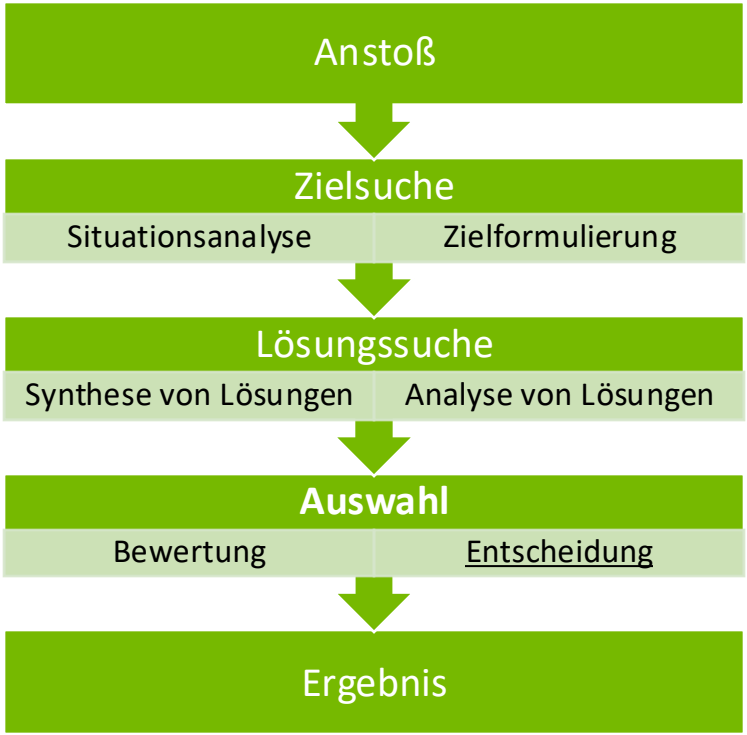

4. Problemlösungsprozess nach Haberfellner.

Ergebnis

- Zufriedenstellende Lösung für den nächsten Schritt (bspw. Implementierung) wurde gefunden
- Anstoß für die nächste „Phase“ ist gegeben
- Sollte keine zufriedenstellende Lösung gefunden werden, kann:
  - Problemlösungsprozess neu angestoßen werden und bspw. die Zielstellungen neu angepasst werden
  - In eine frühere Projektphase zurückgekehrt werden
  - Problemlösungsprozess abgebrochen werden (somit auch die Bearbeitung des Problems)

i.A.a. Haberfellner 2012, Systems Engineering, 12. Auflage, orell füssli

4. Problemlösungsprozess nach Haberfellner.

Gruppenaufgabe:

Ausgangssituation: Die BVG hat sich entschieden rechtzeitig zum Semesterstart intensive Bauarbeiten an den Straßenbahnverbindungen zur HTW durchzuführen.

Problem: Ihr müsst an einem Montagmorgen 8.00 Uhr morgens zu einer wichtigen Klausur erscheinen, die ihr unbedingt bestehen müsst.

Aufgabe: Erarbeitet in Kleinguppen 2-4 Personen eine Lösung für Euer Problem, haltet Euch dabei an den vorgestellten Lösungsprozess nach Haberfellner.

5. CRISP DM. Der Industriestandard für datengetriebene Problemlösung.

5. CRISP DM.

Allgemeine Beschreibung

- **CR**oss **I**ndustry **S**tandard **P**rocess for **D**ata **M**ining
- Industriestandard in datengetriebenen Projekten insb. Maschinelles Lernen (ML) und Künstliche Intelligenz (KI)
- Entwickelt zwischen 1996 und 2000 durch NCR System Engineering, SPSS Inc. und die DaimlerChrysler AG u.a. durch die EU gefördert
- Ziel: einen branchen-, software- und anwendungsunabhängigen standardisierten Prozessablauf des Data Minings für Unternehmen bereitzustellen

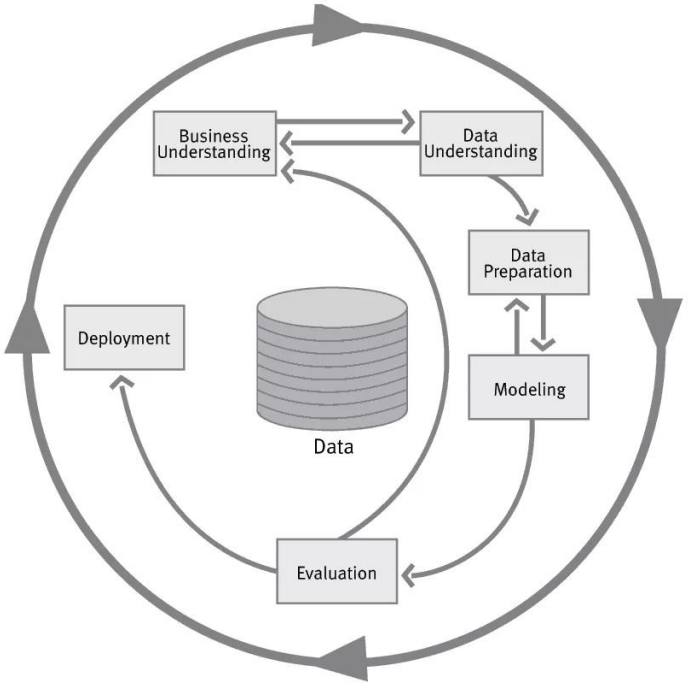

i.A.a. Laurenz Wuttke https://datasolut.com/crisp-dm-standard/ abgerufen am 18.04.2024 14:00

5. CRISP DM.

Allgemeine Beschreibung

- Iteratives Prozessmodell d.h. Vorgehen ist ein Kreislauf
- hin- und herwechseln zwischen den Phasen ist möglich
- Sechs verschiedene Phasen, die jeweils unterschiedliche, relevante Aktivitäten beinhalten:
  - Business Understanding (Aufgabendefinition)
  - Data Understanding (Auswahl der relevanten Datenbestände)
  - Data Preparation (Datenaufbereitung)
  - Modeling (Auswahl und Anwendung von Data Mining Methoden)
  - Evaluation (Bewertung und Interpretation der Ereignisse)
  - Deployment (Anwendung der Ergebnisse)

i.A.a. Laurenz Wuttke https://datasolut.com/crisp-dm-standard/
abgerufen am 18.04.2024 14:00

5. CRISP DM.

Business Understanding (Aufgabendefinition)

Festlegung der Ziele und Anforderungen; Ableitung der konkreten Aufgabenstellung und der groben Vorgehensweise

<u>Bestimmen der Geschäftsziele</u>

- Erarbeiten des Geschäftshintergrunds
- Definieren von Geschäftszielen
- Kriterien für den Unternehmenserfolg

<u>Bewerten der Situation</u>

- Ressourcenbestand
- Anforderungen, Annahmen und Beschränkungen
- Risiken und Notfälle, Terminologie, Kosten-/Nutzen-Analyse

i.A.a. Laurenz Wuttke https://datasolut.com/crisp-dm-standard/ abgerufen am 18.04.2024 14:00

5. CRISP DM.

Business Understanding (Aufgabendefinition)

Festlegung der Ziele und Anforderungen; Ableitung der konkreten Aufgabenstellung und der groben Vorgehensweise

<u>Bestimmen von Data-Mining-Zielen</u>

- Data-Mining-Ziele formulieren
- Erfolgskriterien für das Data-Mining festlegen

<u>Erstellen eines Projektplans</u>

- Planung und Beschreibung der Schritte zur Zielerreichung

i.A.a. Laurenz Wuttke https://datasolut.com/crisp-dm-standard/
abgerufen am 18.04.2024 14:00

5. CRISP DM.

Data Understanding (Auswahl der relevanten Datenbestände)

Datensammlung bzw. erste Sichtung der zur Verfügung stehenden Daten; Ermittlung möglicher Probleme mit Datenqualität

<u>Sammeln von Anfangsdaten</u>

- Vorhandene Daten
- Erworbene Daten
- Zusätzliche Daten

<u>Beschreiben von Daten</u>

- Menge an Daten
- Werttypen
- Codierungsschemata

i.A.a. Laurenz Wuttke https://datasolut.com/crisp-dm-standard/ abgerufen am 18.04.2024 14:00

5. CRISP DM.

Data Understanding (Auswahl der relevanten Datenbestände)

Datensammlung bzw. erste Sichtung der zur Verfügung stehenden Daten; Ermittlung möglicher Probleme mit Datenqualität

<u>Untersuchen von Daten</u>

- Explorative Datenanalyse
- Schreiben eines Berichts zur Datenexploration

<u>Überprüfen der Datenqualität</u>

- Qualitative Datenanalyse
- Schreiben eines Berichts zur Datenqualität

i.A.a. Laurenz Wuttke https://datasolut.com/crisp-dm-standard/ abgerufen am 18.04.2024 14:00

5. CRISP DM.

Data Preparation (Datenaufbereitung)

Datensammlung bzw. erste Sichtung der zur Verfügung stehenden Daten; Ermittlung möglicher Probleme mit Datenqualität

<u>Auswählen von Daten</u>

- Auswahl von Elementen (Zeilen)
- Auswahl von Attributen oder Merkmalen (Spalten)

<u>Bereinigen von Daten</u>

- Fehlende Daten
- Datenfehler
- Codierungsinkonsistenzen
- Fehlende oder ungültige Metadaten

i.A.a. Laurenz Wuttke https://datasolut.com/crisp-dm-standard/ abgerufen am 18.04.2024 14:00

5. CRISP DM.

Data Preparation (Datenaufbereitung)

Datensammlung bzw. erste Sichtung der zur Verfügung stehenden Daten; Ermittlung möglicher Probleme mit Datenqualität

Erstellen neuer Daten

- Ableiten von Attributen (Spalten oder Merkmale)
- Generieren von Datensätzen (Zeilen)

Verbinden von Daten

- Verbinden von Daten
- Anhängen von Daten

i.A.a. Laurenz Wuttke https://datasolut.com/crisp-dm-standard/ abgerufen am 18.04.2024 14:00

5. CRISP DM.

Modeling (Auswahl und Anwendung von Data Mining Methoden)

Anwendung geeigneter Data Mining-Verfahren, Optimierung der Parameter; gewöhnlich Ermittlung mehrerer Modelle

<u>Auswählen der Modellierungsverfahren</u>

- Berücksichtigung der verfügbaren Datentypen
- Berücksichtigung der Data-Mining-Ziele
- Bestimmen der Modellierungsanforderungen

<u>Generieren eines Testdesigns</u>

- Beschreiben der Kriterien für die "Güte" eines Modells
- Definieren der Daten, an denen diese Kriterien getestet werden

i.A.a. Laurenz Wuttke https://datasolut.com/crisp-dm-standard/ abgerufen am 18.04.2024 14:00

5. CRISP DM.

Modeling (Auswahl und Anwendung von Data Mining Methoden)

Anwendung geeigneter Data Mining-Verfahren, Optimierung der Parameter; gewöhnlich Ermittlung mehrerer Modelle

Erstellen der Modelle

- Parametereinstellungen
- Ausführen der Modelle
- Modellbeschreibung

Modellbewertung

- Anwendung des Testdesigns
- Dokumentation der Testergebnisse

i.A.a. Laurenz Wuttke https://datasolut.com/crisp-dm-standard/ abgerufen am 18.04.2024 14:00

5. CRISP DM.

Evaluation (Bewertung und Interpretation der Ereignisse)

Auswahl des Modells, das die Aufgabenstellung am besten erfüllt; Sorgfältiger Abgleich mit der Aufgabenstellung.

- Evaluieren der Ergebnisse
- Bestimmen der nächsten Schritte

i.A.a. Laurenz Wuttke https://datasolut.com/crisp-dm-standard/ abgerufen am 18.04.2024 14:00

5. CRISP DM.

Deployment (Anwendung der Ergebnisse)

Aufbereitung und Präsentation der Ergebnisse; evtl. Integration des Modells in einen Entscheidungsprozess des Auftraggebers

- Planen der Bereitstellung
- Planen von Überwachung und Anpassung
- Erstellen eines Abschlussberichts
- Durchführen einer abschließenden Projektbewertung

i.A.a. Laurenz Wuttke https://datasolut.com/crisp-dm-standard/ abgerufen am 18.04.2024 14:00

5. CRISP DM.

Zeitliche Dimension

- 50%-70% der Zeit für die Datenaufbereitung notwendig
- Nur 20%-30% der veranschlagten Zeit entfallen dabei auf die Bestimmung der relevanten Datenbestände.
- die Modellierung, die Bestimmung der betriebswirtschaftlichen Fragestellung und Erfolgsmessung wird jeweils 10%-20% benötigt
- lediglich 5%-10% der Zeit entfallen auf die Implementierung der erstellten Modelle.

i.A.a. Laurenz Wuttke https://datasolut.com/crisp-dm-standard/ abgerufen am 18.04.2024 14:00

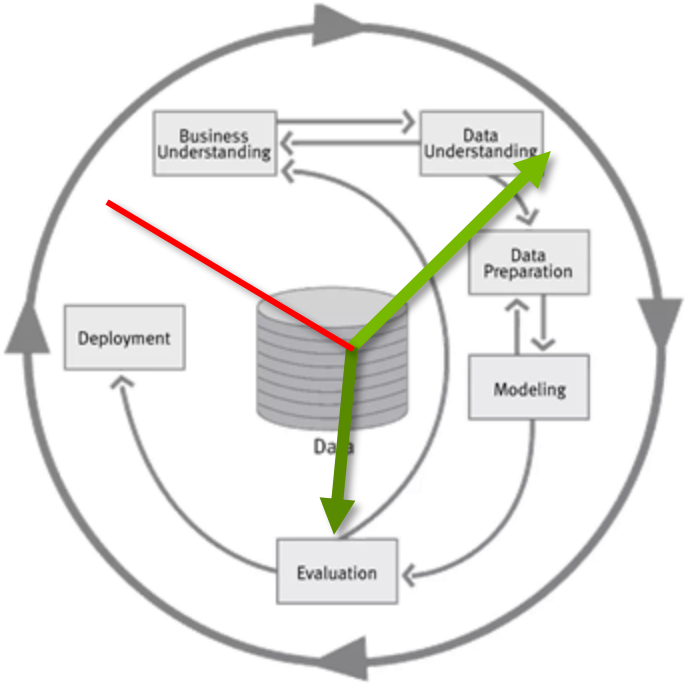

5. CRISP DM.

Kompetenzen von Data-Scientists

- Hacking-Fähigkeiten: Manipulation von Textdateien, vektorisierte Operationen, algorithmisches Denken
- Mathematik & Statistik: Anwendung geeigneter Methoden, Verständnis für Regressionsanalyse
- Inhaltliche Expertise: Wissen um Entdeckungen und Wissensaufbau, Hypothesentestung

Interdisziplinarität

- Kombination dieser Fähigkeiten ist essentiell für echte Data Science

Maschinelles Lernen vs. Data Science

- Daten + Mathematik/Statistik = Maschinelles Lernen
- Daten + Mathematik/Statistik + Inhalt = Data Science

Gefahrenzone

- Gefährliches Halbwissen, das zu Missverständnissen oder Fehlinterpretationen führen

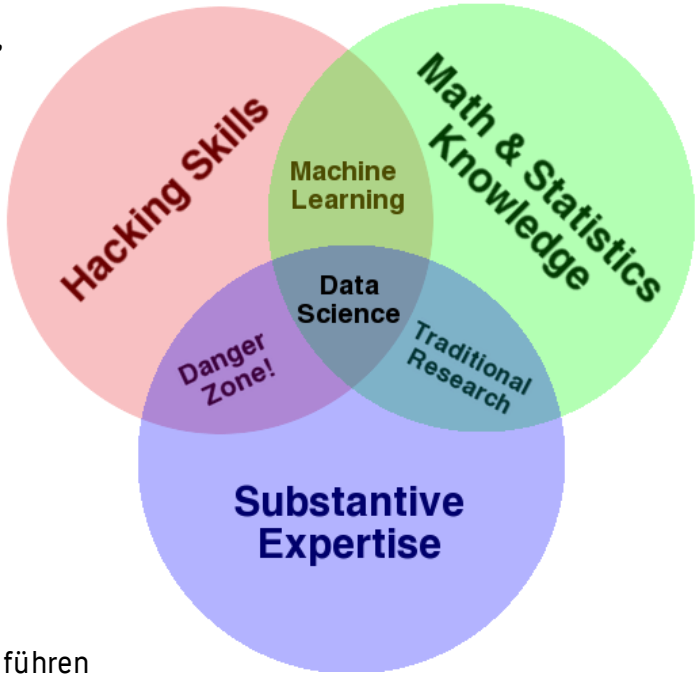

5. CRISP DM.

Gruppenaufgabe:

Ausgangssituation: Ihr arbeitet in einem Logistik-Unternehmen, das innerstädtich Pakete zustellt. Spritkosten sind für euch ein relevanter Kostenfaktor.

Problem: Ihr sollt ein Model entwickeln, das euren Fahrern den optimalen Zeitpunkt zum Tanken vorschlägt. Das soll eure Spritkosten minimieren.

Aufgabe: Arbeitet in Kleinguppen 2-4 Personen. Diskutiert welche konkreten Aufgaben ihr in den verschiedenen Phasen von CRISP-DM im Bezug auf euer Problem habt, welche Probleme auf euch zukommen könnten und welche Lösungsmöglichkeiten ihr hättet. Es soll keine konkrete Lösung “entwickelt“ werden!

Vielen Dank.

www.htw-berlin.de

Hochschule für Technik
und Wirtschaft Berlin

University of Applied Sciences